

Sistema de Recomendación de Vehículos Usados Basado en Machine Learning e Integrado en un Agente Inteligente

Andrés Bonilla Solano
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
andbonilla@estudiantec.cr

Mary Paz Álvarez Navarrete
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
mar01alvarez@estudiantec.cr

Resumen—

Index Terms—Machine Learning, LightGBM, Sistema de Recomendación, SHAP, Agente Inteligente, Vehículos Usados, Gradient Boosting

I. INTRODUCCIÓN

La adquisición de vehículos usados es parte de una de las decisiones financieras más significativas para los consumidores, especialmente en situaciones donde el acceso a vehículos nuevos es limitado por su costo. En mercados como el estadounidense, plataformas de clasificados en línea como Craigslist concentran cientos de miles de anuncios de venta con características heterogéneas, lo que dificulta que un comprador pueda evaluar objetivamente si un vehículo representa una oferta razonable dentro de su presupuesto.

El precio de un vehículo usado no puede estimarse mediante reglas simples, debido a que depende de la interacción no lineal de múltiples factores: el año de fabricación, el kilometraje acumulado, la marca, el tipo de carrocería, el estado mecánico declarado y las condiciones del mercado regional, entre otros. Esto hace que los enfoques basados en heurísticas o modelos lineales sean insuficientes para capturar la variabilidad real del mercado.

Ante esta problemática, se propone un sistema de recomendación de vehículos usados basado en técnicas de aprendizaje automático, diseñado para asistir a los compradores en la identificación de vehículos con una relación calidad-precio favorable. El sistema fue desarrollado a partir de un conjunto de datos de 426,880 registros reales provenientes de Craigslist [7], el cual fue sometido a un proceso exhaustivo de limpieza y preprocesamiento que redujo el conjunto de datos a 364,546 registros utilizables. Sobre este conjunto se evaluaron seis modelos de aprendizaje automático, incluyendo Regresión Lineal, Ridge Regresión, Decision Tree, Random Forest, XGBoost y LightGBM, mediante un protocolo de validación temporal estricto. Como resultado, LightGBM [5] fue seleccionado como modelo principal al demostrar el mejor equilibrio entre precisión predictiva y capacidad de generalización. Posteriormente, el modelo fue optimizado mediante

búsqueda aleatoria de hiperparámetros y evaluado sobre un conjunto de prueba independiente, obteniendo un error absoluto medio de \$4,000 y un coeficiente de determinación (R^2) de 0.762. Estos resultados representan una mejora del 27.4 % con respecto al modelo de referencia.

Como componente transversal del sistema, el modelo fue integrado en un agente inteligente con capacidad de *tool calling*, capaz de recibir consultas en lenguaje natural, invocar el modelo de predicción como herramienta y retornar recomendaciones justificadas mediante explicaciones generadas con SHAP [2]. Esta integración permite que el sistema no solo prediga precios, sino que explique al usuario los factores que determinan el valor estimado de cada vehículo.

Las contribuciones principales de este trabajo son las siguientes:

- El desarrollo de un pipeline reproducible para la predicción de precios de vehículos usados, incorporando estrategias para prevenir *data leakage* por medio de la partición temporal de los datos.
- La evaluación comparativa de varios modelos de aprendizaje automático por medio de un protocolo de validación temporal, considerando tanto el desempeño predictivo como su capacidad de generalización.
- La aplicación de técnicas de explicabilidad basadas en SHAP para identificar los factores más influyentes en la estimación de precios.
- La integración del modelo predictivo en un agente inteligente con capacidad de *tool calling*, permitiendo consultas en lenguaje natural y recomendaciones justificadas.

Dentro del artículo se encuentran las siguientes secciones: la Sección II presenta los trabajos relacionados; la Sección III describe la metodología empleada; la Sección IV reporta los experimentos y resultados obtenidos; la Sección V discute los hallazgos principales y las limitaciones del sistema; y la Sección VI presenta las conclusiones y el trabajo futuro.

II. TRABAJOS RELACIONADOS

La predicción de precios de vehículos usados mediante aprendizaje automático ha sido abordada desde múltiples

enfoques. Cui et al. [6] propusieron un marco iterativo que combina XGBoost y LightGBM para la predicción de precios bajo grandes volúmenes de características, fusionando las predicciones de una red residual profunda con las features originales como entrada al marco iterativo. Sus experimentos demostraron que esta combinación supera al Random Forest y a las redes residuales individuales en precisión. A diferencia de este enfoque, este trabajo evalúa cada modelo de forma independiente bajo un protocolo de validación temporal estricto, priorizando la capacidad de generalización sobre datos futuros mediante el análisis del Gap R^2 como métrica de overfitting.

En una línea similar, trabajos previos han comparado múltiples modelos de aprendizaje automático para este problema, incluyendo regresión lineal, K-Nearest Neighbors, Random Forest y XGBoost sobre datasets de vehículos usados de diversas regiones [8]. Estos estudios coinciden en que los modelos basados en árboles de decisión superan consistentemente a los modelos lineales, confirmando la necesidad de capturar relaciones no lineales entre las variables del mercado automotriz. Sin embargo, la mayoría de estos trabajos no implementan partición temporal de los datos ni analizan el riesgo de data leakage, limitaciones que el presente trabajo aborda explícitamente.

El algoritmo XGBoost, propuesto por Chen y Guestrin [4], introdujo un sistema escalable de gradient boosting basado en árboles con optimizaciones de caché, compresión de datos y soporte para datos dispersos. Su adopción generalizada en competencias de aprendizaje automático lo convirtió en el punto de referencia para datos tabulares. Posteriormente, Ke et al. [5] propusieron LightGBM, que supera a XGBoost en eficiencia mediante dos innovaciones algorítmicas: *Gradient-based One-Side Sampling* (GOSS), que reduce el tamaño del conjunto de entrenamiento priorizando instancias con gradientes grandes, y *Exclusive Feature Bundling* (EFB), que reduce el número de features agrupando variables mutuamente excluyentes. Los experimentos de los autores demuestran que LightGBM acelera el entrenamiento hasta 20 veces respecto a GBDT convencional manteniendo una precisión comparable. En el presente trabajo se confirma esta ventaja de velocidad: LightGBM completó la validación cruzada en 11 segundos frente a los 83 segundos de Random Forest sobre un dataset de 255,182 registros.

La explicabilidad de los modelos de aprendizaje automático en aplicaciones de alto impacto ha cobrado relevancia creciente. Lundberg y Lee [2] propusieron SHAP (SHapley Additive exPlanations), un marco unificado para la interpretación de predicciones individuales basado en valores de Shapley de la teoría de juegos. SHAP asigna a cada feature un valor de importancia para una predicción específica, con la propiedad de que la suma de todos los valores SHAP reproduce exactamente la predicción del modelo. A diferencia de métodos anteriores como LIME, SHAP presenta consistencia teórica garantizada y permite tanto explicaciones locales (por predicción) como globales (sobre todo el dataset). En el presente trabajo se aplica TreeExplainer, la variante optimizada de SHAP para modelos basados en árboles, sobre una muestra de 2,000 registros

del conjunto de prueba. Los resultados revelan que el año y el kilometraje dominan las predicciones de precio, confirmando las correlaciones identificadas en el análisis exploratorio y validando la coherencia del modelo con el conocimiento del dominio.

La integración de modelos predictivos en agentes inteligentes representa una tendencia emergente en la literatura. Trabajos recientes han demostrado que los LLMs pueden actuar como orquestadores de herramientas externas mediante *toolcalling*, descomponiendo tareas complejas en sub tareas manejables y seleccionando las herramientas apropiadas para cada una [9]. En el contexto de sistemas de recomendación, esta capacidad permite que el agente no solo recupere información sino que la interprete y la comunique al usuario en lenguaje natural. A diferencia de los sistemas de recomendación tradicionales basados en filtrado colaborativo [1], el enfoque propuesto en este trabajo emplea el modelo de predicción de precios como herramienta del agente, permitiendo recomendaciones justificadas con explicaciones SHAP que detallan los factores determinantes del precio estimado para cada vehículo.

III. METODOLOGÍA

III-A. Dataset y Preprocesamiento

El dataset utilizado corresponde a anuncios de vehículos usados publicados en la plataforma de Craigslist, recopilado por Austin Reese y disponible en Kaggle. Originalmente contiene 426 880 registros y 26 variables que describen las características del vehículo y del anuncio. Luego de realizar un análisis, se determinó que existían columnas sin valor predictivo o con riesgo de *data leakage* por lo que no se tomaron en cuenta. Las nueve columnas eliminadas son: `id`, `url`, `region_url`, `image_url`, `VIN`, `lat`, `long`, `county` y `description`. La razón para borrar la columna que contiene la descripción es que frecuentemente contiene el precio del vehículo de forma explícita en el texto libre del vendedor. Se aplicaron filtros de valores atípicos basados en rangos lógicos del mercado: precio entre \$500 y \$100 000, odómetro entre 100 y 500 000 millas, y año de fabricación entre 1990 y 2022. La columna `size` fue eliminada por presentar un 71.77 % de valores nulos, umbral a partir del cual la imputación introduce ruido artificial. Para las columnas `cylinders`, `condition` y `drive`, con porcentajes de nulos entre 30 % y 42 %, se aplicó imputación por moda agrupada según el fabricante y el tipo de vehículo, dado que vehículos de características similares tienden a compartir estos atributos. Tras aplicar todos los filtros, el dataset quedó conformado por 364 546 registros listos para ser usados en las siguientes partes del proyecto.

III-B. Pipeline de Transformación

Las variables de entrada se organizaron en tres grupos según su naturaleza y el tratamiento que requieren. Las variables numéricas `year` y `odometer` se normalizaron con `StandardScaler` para garantizar que las features sigan una distribución normal estándar. También, hay variables categóricas con orden semántico inherente, como es el caso de `condition` y `cylinders`, se codificaron con

OrdinalEncoder respetando sus jerarquías naturales. Para la condición, las categorías van de vehículos declarados como pérdida total hasta otros que pueden ser catalogados como nuevos, y de 3 a 12 cilindros en el caso de cilindrada. El resto de variables categóricas no tienen un orden natural (manufacturer, fuel, transmission, drive, type, title_status) por lo que se codificaron con OneHotEncoder y con drop='first' para evitar multicolinealidad en los modelos lineales. Todo el preprocesamiento se encapsuló en un ColumnTransformer integrado dentro de un Pipeline de scikit-learn junto al modelo de predicción. Con el fin de prevenir el *data leakage* se tomó esta decisión de usar un pipeline ya que los parámetros de escalado, imputación y codificación se aprenden exclusivamente con los datos de entrenamiento y se aplican posteriormente al conjunto de validación y prueba. Finalmente, el resultado tras la expansión por el uso del OneHotEncoder es un espacio de 67 de features.

III-C. Partición Temporal

Para el presente proyecto se adoptó una estrategia de partición temporal basada en la columna `posting_date` ya que para este caso es mejor que una partición aleatoria. Esto se debe a que si se usa una partición aleatoria se permitiría que el modelo entrene con anuncios publicados después de los que se usan para evaluación, lo que llevaría a simular un conocimiento del futuro que no existe en producción. Asimismo, el dataset se ordenó cronológicamente y se dividió en tres conjuntos contiguos y no solapados: 70 % de los registros más antiguos para entrenamiento (255 182 registros, hasta el 30 de abril de 2021), 15 % intermedios para validación durante el ajuste de hiperparámetros (54 681 registros, del 30 de abril al 3 de mayo de 2021), y 15 % más recientes para la prueba final (54 683 registros, del 3 al 5 de mayo de 2021). Es importante mencionar que el conjunto de prueba se utilizó únicamente para la evaluación final del modelo seleccionado, garantizando que ninguna decisión de diseño o ajuste de hiperparámetros fue influenciada por su contenido.

III-D. Modelos y Protocolo de Evaluación

Se evaluaron seis modelos de aprendizaje automático bajo un protocolo unificado de validación cruzada temporal. Para garantizar que las diferencias en rendimiento sean atribuibles exclusivamente al modelo y no al preprocesamiento, todos los modelos reciben el mismo ColumnTransformer definido en la subsección anterior como primera etapa de un Pipeline de scikit-learn.

El protocolo de evaluación consiste en un esquema de validación TimeSeriesSplit con $k = 5$ folds sobre el conjunto de entrenamiento, respetando el orden cronológico en cada partición. Se calculan tres métricas por modelo: MAE, RMSE y R^2 . Además, se reporta el Gap en R^2 , definido como la diferencia entre el R^2 sobre el conjunto de entrenamiento y el R^2 sobre el conjunto de validación:

$$\text{Gap-}R^2 = R^2_{\text{train}} - R^2_{\text{val}} \quad (1)$$

Un Gap- R^2 elevado indica que el modelo memoriza los datos de entrenamiento en lugar de aprender patrones generalizables, condición conocida como *overfitting*. Se establece como umbral de alerta un Gap- R^2 superior a 0.10.

Los seis modelos evaluados y sus configuraciones iniciales son los siguientes:

Regresión Lineal (Baseline 1): Modelo de referencia mínimo que asume relaciones lineales entre las variables y el precio. Sirve para cuantificar cuánto se puede explicar sin capturar no-linealidades.

Ridge Regression (Baseline 2): Extensión regularizada de la regresión lineal con penalización L2 ($\alpha=1,0$). Mitiga los coeficientes extremos generados por categorías poco frecuentes como marcas de lujo con pocos registros en el dataset.

Decision Tree: Árbol de decisión con profundidad máxima de cinco niveles y un mínimo de 50 muestras por hoja (`max_depth=5`, `min_samples_leaf=50`). Se incluye por su valor interpretativo: permite visualizar directamente la lógica de decisión del modelo en los primeros tres niveles.

Random Forest: Ensemble de 100 árboles de decisión entrenados sobre muestras aleatorias del dataset mediante bagging (`n_estimators=100`, `min_samples_leaf=5`). Captura relaciones no lineales sin transformaciones manuales, por ejemplo la depreciación exponencial observada en el EDA entre año de fabricación y precio.

XGBoost: Algoritmo de gradient boosting que construye árboles de forma secuencial por niveles (*depth-wise*) [4]. Se configura con 300 árboles, tasa de aprendizaje de 0.05, profundidad máxima de 6 y submuestreo de 80 % tanto de filas (`subsample`) como de features (`colsample_bytree`) por árbol.

LightGBM: Algoritmo de gradient boosting que divide los árboles por hojas (*leaf-wise*) en lugar de por niveles, logrando mayor velocidad y precisión en datasets grandes [5]. Se configura con 300 árboles, tasa de aprendizaje de 0.05 y 63 hojas por árbol (`num_leaves=63`).

Los resultados de la comparación se presentan en la Tabla I. Random Forest obtiene el menor MAE (\$3,798), pero con un Gap R^2 de 0.124 que indica overfitting moderado. LightGBM alcanza el mayor R^2 (0.798) con un Gap R^2 de 0.058, superando a Random Forest en capacidad de generalización con una diferencia en MAE de solo \$189 (4.7 %). La velocidad de entrenamiento de LightGBM (22s frente a 179s de Random Forest) hace que el proceso de optimización de hiperparámetros sea 8 veces más rápido. Por estas razones, LightGBM es seleccionado como modelo principal para la siguiente etapa.

III-E. Optimización de Hiperparámetros

La optimización de hiperparámetros se realizó mediante RandomizedSearchCV sobre LightGBM, utilizando el mismo protocolo de TimeSeriesSplit $k=5$ empleado en la evaluación de candidatos. Se optó por búsqueda aleatoria en lugar de búsqueda exhaustiva (GridSearchCV) dado que el espacio de seis hiperparámetros con los rangos definidos implica un número de combinaciones que haría inviable la

evaluación completa con el tamaño del dataset. Con 50 iteraciones aleatorias y 5 folds por iteración se realizaron 250 entrenamientos en total, con una duración de aproximadamente 24 minutos por ronda de búsqueda.

El espacio de búsqueda definido fue el siguiente:

- `n_estimators`: entero uniforme en [200, 800]
- `learning_rate`: continuo uniforme en [0,01, 0,20]
- `num_leaves`: entero uniforme en [20, 150]
- `min_child_samples`: entero uniforme en [20, 200]
- `subsample`: continuo uniforme en [0,60, 1,00]
- `colsample_bytree`: continuo uniforme en [0,60, 1,00]

La primera búsqueda (*Tuning v1*) encontró parámetros agresivos: `learning_rate`=0.181, `num_leaves`=118 y `min_child_samples`=28. Esta combinación redujo el MAE de \$3,987 a \$3,588, pero aumentó el Gap R^2 de 0.058 a 0.102, indicando mayor overfitting que el modelo sin afinar. El `learning_rate` elevado genera correcciones grandes en cada ronda de boosting, lo que favorece la memorización de patrones específicos del conjunto de entrenamiento.

Ante este resultado, se realizó una segunda búsqueda (*Tuning v2*) con rangos más conservadores: `learning_rate` limitado a [0,01, 0,08], `num_leaves` a [20, 80] y `min_child_samples` elevado a [50, 300]. Para compensar el menor ritmo de aprendizaje, el rango de `n_estimators` se amplió a [400, 900]. Los mejores parámetros encontrados fueron: `learning_rate`=0.073, `num_leaves`=67, `min_child_samples`=63, `n_estimators`=750, `subsample`=0.714 y `colsample_bytree`=0.929.

El modelo resultante (*Tuning v2*) obtuvo un MAE de \$3,660 sobre el conjunto de validación, con un Gap R^2 de 0.074 — reducción del 27.6 % respecto al gap de *Tuning v1*. Los resultados comparativos de las tres versiones de LightGBM se presentan en la Tabla II. Se selecciona *Tuning v2* como modelo final por representar el mejor balance entre precisión (\$327 de mejora en MAE respecto al modelo sin afinar) y capacidad de generalización (Gap R^2 de 0.074 frente a 0.102 de *Tuning v1*).

III-F. Explicabilidad con SHAP

Para garantizar la interpretabilidad del modelo final se aplicó SHAP (*SHapley Additive exPlanations*) [2], un marco unificado de explicabilidad basado en la teoría de juegos de Shapley. SHAP asigna a cada feature un valor de importancia para cada predicción individual, con la propiedad de que la suma de todos los valores SHAP reproduce exactamente la predicción del modelo, lo que garantiza consistencia local y global.

Se utilizó *TreeExplainer*, la variante optimizada de SHAP para modelos basados en árboles, aplicada sobre el modelo final *LightGBM Tuning v2*. Dado que SHAP requiere datos en formato numérico, se transformó previamente `X_test` mediante el *ColumnTransformer* del pipeline. El análisis se realizó sobre una muestra aleatoria de 2,000 registros del conjunto de prueba (semilla SEED=42) para mantener la viabilidad computacional.

Se generaron tres visualizaciones complementarias. El *summary plot* muestra la distribución de los valores SHAP para las 15 features más influyentes sobre toda la muestra, donde el color codifica el valor real de la variable (rojo para valores altos, azul para valores bajos) y el eje horizontal representa el impacto en dólares sobre el precio predicho. El *bar plot* presenta el ranking de importancia como el promedio del valor absoluto de SHAP por feature, permitiendo una lectura directa de la magnitud de influencia de cada variable. Finalmente, el *waterfall plot* desglosa la predicción individual del vehículo con precio más cercano a la mediana del mercado (\$14,444), mostrando la contribución positiva o negativa de cada feature desde el precio base de \$19,809 hasta el precio predicho de \$14,287, con un error de solo \$157.

Los resultados del análisis SHAP y su interpretación se presentan en la Sección V.

III-G. Integración en Agente Inteligente

IV. EXPERIMENTOS Y RESULTADOS

IV-A. Comparación de Modelos Candidatos

Se evaluaron seis modelos mediante validación cruzada temporal (*TimeSeriesSplit* $k=5$) sobre el conjunto de entrenamiento de 255,182 registros. La Tabla I presenta los resultados consolidados ordenados por MAE ascendente.

Cuadro I
COMPARACIÓN DE MODELOS - VALIDATION SET (CV $k=5$)

Modelo	MAE (\$)	R^2	Gap R^2	t(s)
Random Forest	3,798	0.797	0.124	179
LightGBM	3,987	0.798	0.058	22
XGBoost	4,157	0.786	0.044	30
Reg. Lineal (B1)	5,510	0.655	—	—
Ridge (B2)	5,633	0.670	0.017	6
Decision Tree	5,866	0.637	0.019	6

Los modelos basados en árboles de decisión no lineales (Random Forest, LightGBM y XGBoost) superan consistentemente a los modelos lineales (Regresión Lineal y Ridge) en todas las métricas, con reducciones en MAE de entre \$1,551 y \$2,068 respecto al mejor baseline. Este resultado confirma que las relaciones entre las variables del mercado de vehículos usados no son capturables mediante transformaciones lineales, tal como sugería la tendencia exponencial observada en el diagrama de dispersión precio-año del EDA.

Random Forest obtiene el menor MAE (\$3,798) pero presenta el mayor Gap R^2 (0.124), lo que indica overfitting moderado: su R^2 en entrenamiento es de 0.921 frente a 0.797 en validación. LightGBM alcanza el R^2 más alto (0.798) con un Gap R^2 de 0.058, lo que representa la mitad del overfitting de Random Forest, con una diferencia de MAE de solo \$189 (4.7 %). XGBoost exhibe el menor Gap R^2 de todos los modelos no lineales (0.044), pero su MAE es \$370 superior al de LightGBM y su R^2 es 0.012 inferior. Por las razones expuestas en la Subsección III-E, LightGBM es seleccionado como modelo principal para la optimización de hiperparámetros.




Figura 1. Comparación de MAE y R² en validación para los seis modelos evaluados.

IV-B. Optimización de Hiperparámetros

La Tabla II presenta los resultados de las dos rondas de búsqueda aleatoria sobre el conjunto de validación.

Cuadro II
COMPARACIÓN DE VERSIONES DE LIGHTGBM (VALIDATION SET)

Versión	MAE (\$)	R²	Gap R²
Original (s6)	3,987	0.798	0.058
Tuning v1 (agresivo)	3,588	0.799	0.102
Tuning v2 (conserv.)	3,660	0.792	0.074

Tuning v1 reduce el MAE en \$399 respecto al modelo original pero aumenta el Gap R² de 0.058 a 0.102 como consecuencia de los parámetros agresivos encontrados (`learning_rate=0.181`, `num_leaves=118`). *Tuning v2* alcanza un MAE de \$3,660 con un Gap R² de 0.074, reduciendo el overfitting de *Tuning v1* en un 27.6% a costa de \$72 adicionales en MAE. Se selecciona *Tuning v2* como modelo final por representar el mejor balance entre precisión y generalización.




Figura 2. MAE y Gap R² para las tres versiones de LightGBM. Tuning v2 logra el mejor balance entre precisión y generalización.

IV-C. Evaluación Final en Test Set

El modelo *LightGBM Tuning v2* fue evaluado sobre el conjunto de prueba de 54,683 registros (período 2021-05-03 al 2021-05-05), que permaneció bloqueado durante todo el desarrollo anterior. Los resultados se presentan en la Tabla III.

Cuadro III
MÉTRICAS DEL MODELO FINAL EN TEST SET VS VALIDATION SET

Métrica	Val	Test	Diferencia
MAE (\$)	3,660	3,999	+339 (+9.3 %)
RMSE (\$)	6,309	6,917	+608 (+9.6 %)
R²	0.792	0.762	-0.030

El MAE en test (\$3,999) representa una mejora del 27.4% respecto al mejor baseline (Regresión Lineal, \$5,510). La diferencia entre validación y test es de \$339 en MAE (9.3%), lo que confirma que el modelo generaliza adecuadamente a datos no vistos bajo el esquema de partición temporal adoptado. La caída de R² de 0.792 a 0.762 es consistente con el desplazamiento temporal entre los conjuntos: los anuncios de mayo de 2021 presentan una distribución de precios levemente diferente a la de abril, efecto esperable en datos de mercado con variación temporal.

La distribución de errores muestra una media de \$24, lo que indica que el modelo no presenta sesgo sistemático de sobreestimación ni subestimación. La curva de errores acumulados revela que el 80% de las predicciones tienen un error absoluto menor a \$6,000.




Figura 3. Evaluación final del modelo sobre el test set. (a) Precio real vs predicho. (b) Distribución de errores centrada en \$24. (c) MAE por rango de precio. (d) Curva de errores acumulados.

IV-D. Análisis por Rango de Precio

La Tabla IV desagrega el MAE por segmento de precio para identificar dónde el modelo presenta mayor y menor precisión.

Cuadro IV
MAE Y ERROR PORCENTUAL POR RANGO DE PRECIO EN TEST SET

Rango	Registros	MAE (\$)	Error (%)
\$0 – \$5k	9,579	4,164	370.5
\$5k – \$15k	19,307	2,438	26.4
\$15k – \$30k	16,150	3,836	17.7
\$30k – \$60k	8,863	6,145	15.3
\$60k – \$100k	784	19,583	26.0

El segmento \$5,000–\$15,000 presenta el mejor rendimiento con un MAE de \$2,438 y un error porcentual del 26.4 %. Este rango concentra el 35.3 % de los registros del test set, lo que lo convierte en el segmento más relevante para el sistema de recomendación dado que corresponde al mercado de mayor volumen de transacciones en Craigslist. El rendimiento degradado en el segmento \$60,000–\$100,000 (MAE de \$19,583) se atribuye a la baja representación de ese rango en el dataset: solo 784 registros en el test set (1.4 %) frente a 19,307 en el segmento de mayor volumen.

El error porcentual del 370.5 % en el segmento \$0–\$5,000 no refleja una limitación del modelo sino una limitación del dataset: anuncios con precios simbólicos (\$838, \$883, \$1,008) pero con características de vehículos de alto valor que sobrevivieron los filtros de limpieza. Estos casos se analizan en detalle en la Sección V.

IV-E. Análisis de Explicabilidad SHAP

El análisis SHAP sobre una muestra de 2,000 registros del test set revela la importancia global de cada variable y su dirección de influencia sobre el precio predicho. La Tabla V presenta el ranking de las diez variables más influyentes medido como el promedio del valor absoluto de SHAP.

Cuadro V
TOP 10 VARIABLES POR IMPORTANCIA SHAP PROMEDIO

Variable	Importancia SHAP (\$)
year	6,054
odometer	3,188
cylinders	2,560
fuel_gas	2,070
drive_fwd	1,565
type_sedan	526
fuel_other	518
type_pickup	325
transmission_other	303
type_truck	303

Las variables `year` y `odometer` dominan el ranking con importancias de \$6,054 y \$3,188 respectivamente, confirmando las correlaciones identificadas en el EDA de la Etapa 1 ($r=0,58$ y $r=-0,54$). Existe una brecha pronunciada entre las primeras cinco variables (\$1,565–\$6,054) y el resto (menos de \$530), lo que indica que el precio de un vehículo usado en este dataset está determinado principalmente por cinco factores: año de fabricación, kilometraje, número de cilindros, tipo de combustible y tracción.




Figura 4. SHAP Summary Plot sobre 2,000 registros del test set. Rojo = valor alto de la feature, Azul = valor bajo. El eje horizontal representa el impacto en dólares sobre el precio predicho.

El *waterfall plot* (Fig. 5) ilustra la predicción del vehículo con precio más cercano a la mediana del mercado. El modelo parte de un precio base de \$19,809 (promedio del dataset) y ajusta hacia abajo por ser marca Chrysler (−\$3,287), tracción delantera (−\$2,004) y combustible gasolina (−\$1,317), mientras que el bajo kilometraje (+\$797) y el tipo de vehículo (+\$758) contribuyen positivamente. El precio predicho resultante es \$14,287 frente a un precio real de \$14,444, con un error de \$157.




Figura 5. SHAP Waterfall para el vehículo con precio más cercano a la mediana (\$14,444). Precio base: \$19,809. Precio predicho: \$14,287. Error: \$157.

IV-F. Resultados del Agente Inteligente

V. DISCUSIÓN

V-A. Hallazgos de Explicabilidad (SHAP)

El análisis SHAP sobre el modelo final *LightGBM Tuning v2* permite validar que el modelo aprendió relaciones económicamente coherentes con el mercado de vehículos usados, y revela hallazgos que no eran evidentes en el análisis exploratorio inicial.

Hallazgo 1: Dominio de variables mecánicas básicas.

El año de fabricación (*year*) y el kilometraje (*odometer*) lideran el ranking con importancias SHAP de \$6,054 y \$3,188 respectivamente, confirmando las correlaciones identificadas en el EDA ($r=0,58$ y $r=-0,54$). El *summary plot* (Fig. 4) muestra que vehículos con año de fabricación reciente; representados en rojo; acumulan valores SHAP positivos de hasta \$20,000, mientras que vehículos con años antiguos — representados en azul — presentan valores negativos de hasta $-\$15,000$. El odómetro exhibe el patrón inverso: mayor kilometraje reduce el precio predicho, consistente con la depreciación por uso documentada en el mercado automotriz [1].

Hallazgo 2: Importancia del número de cilindros.

La variable *cylinders* ocupa la tercera posición con una importancia SHAP de \$2,560, superando a *condition* (posición 12) y a cualquier marca específica. Este resultado no era predecible a partir del análisis de correlaciones lineales

del EDA, donde la variable no presentaba una correlación directa con el precio comparable a la de *year* u *odometer*. SHAP captura la interacción no lineal entre cilindros y otras variables: motores de mayor cilindrada no solo implican un precio más alto de forma directa, sino que se asocian con tipos de vehículo (pickup, SUV, camión) que retienen mejor su valor en el mercado estadounidense.

Hallazgo 3: Comportamiento de variables de combustible y tracción.

La variable *fuel_gas* (combustible gasolina) presenta valores SHAP negativos para la mayoría de los registros, lo que indica que ser de gasolina baja el precio predicho relativo al promedio. Este resultado es contraintuitivo en un primer análisis pero tiene una explicación estructural: los vehículos de combustible alternativo (diesel, híbrido, eléctrico) tienen precios promedio más altos en el dataset dado que son modelos más recientes o de gama superior. De forma análoga, la tracción delantera (*drive_fwd*) contribuye negativamente al precio, en contraste con la tracción integral (4WD) y trasera (RWD) que se asocian a vehículos de mayor valor.

Hallazgo 4: Ausencia de patrones espurios.

El ranking de importancia SHAP no presenta variables con alta influencia que carezcan de justificación económica. Si el modelo hubiera aprendido patrones spurious derivados de data leakage o de correlaciones espúreas en el dataset, variables como *region*, *state* o *posting_date*; excluidas explícitamente del pipeline; habrían aparecido en posiciones superiores. La coherencia del ranking con el conocimiento del dominio valida que el protocolo de prevención de data leakage descrito en la Subsección III-C fue efectivo.

Análisis individual: waterfall plot.

El *waterfall plot* (Fig. 5) ilustra la descomposición de la predicción para el vehículo con precio más cercano a la mediana del mercado (\$14,444). Partiendo del precio base de \$19,809, las características del vehículo ajustan la predicción hacia abajo en \$5,522 netos: la marca Chrysler resta \$3,287, la tracción delantera resta \$2,004 y el combustible gasolina resta \$1,317, mientras que el bajo kilometraje aporta +\$797 y el tipo de carrocería aporta +\$758. El precio predicho resultante (\$14,287) difiere del precio real en solo \$157, con todos los ajustes siendo económicamente justificables. Esta capacidad de descomposición individual constituye la base para las explicaciones generadas por el agente inteligente en la Etapa 3, donde cada recomendación puede acompañarse de un desglose detallado de los factores que determinan el precio estimado del vehículo.

V-B. Limitaciones

VI. CONCLUSIONES

REFERENCIAS

- [1] C. C. Aggarwal, *Recommender Systems: The Textbook*. Springer, 2016.
- [2] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, vol. 30, pp. 4765–4774, 2017.
- [3] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 4, 2012.

- [4] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD*, pp. 785–794, 2016.
- [5] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems*, vol. 30, pp. 3146–3154, 2017.
- [6] B. Cui, Z. Ye, H. Zhao, Z. Renqing, L. Meng, and Y. Yang, "Used car price prediction based on the iterative framework of XG-Boost+LightGBM," *Electronics*, vol. 11, no. 18, p. 2932, 2022.
- [7] F. Sulianta, E. Amalia, and A. Arif, "Analysis of consumer preferences for used cars using k-means clustering," *The Indonesian Journal of Computer Science*, 2024.
- [8] "Forecasting vehicle prices using machine learning techniques," *International Journal of Engineering Research & Technology*, vol. 11, 2022.
- [9] T. Schick et al., "Toolformer: Language models can teach themselves to use tools," in *Advances in Neural Information Processing Systems*, vol. 36, 2024.